

CardioIA — A Busca de Dados: Preparando o Terreno para a Inteligência Cardiológica

Documento-resumo da atividade

Aluno	Guilherme Yamada Dantas
RM	rm568506
Repositório	https://github.com/japatraderdev99/fiap-preparando-terreno-para-inteligencia-cardiologica
Data	2 de setembro de 2026

1. Introdução

O CardioIA é um projeto acadêmico que, ao longo de sete fases, propõe a construção de uma plataforma capaz de simular o funcionamento de um serviço de cardiologia apoiado por inteligência artificial, com atribuições de triagem, diagnóstico assistido, monitoramento remoto e previsão de eventos. Esta primeira fase não envolve a construção de modelos, e sim a preparação dos dados que os alimentarão. O trabalho consistiu em localizar, organizar e documentar três conjuntos — dados numéricos de pacientes, textos sobre saúde cardiovascular e imagens de exame cardiológico —, avaliando desde já a sua procedência, a sua qualidade e os seus limites.

A obtenção de dados em saúde é uma das etapas mais trabalhosas de um projeto de inteligência artificial. As informações clínicas costumam estar dispersas, em formatos heterogêneos ou sujeitas a autorização de acesso, por envolverem dados sensíveis. Diante disso, foram priorizadas fontes públicas, de licença conhecida e sem informação que identifique pacientes, ainda que a escolha implique trabalhar com bases construídas em outros países e em outras épocas, o que impõe limitações discutidas na seção 5.

O Quadro 1 sintetiza os três conjuntos entregues.

Quadro 1 — Síntese dos conjuntos de dados da Fase 1

Conjunto	Fonte	Volume (mínimo exigido)	Formato	Licença
Númérico	UCI Heart Disease (quatro instituições)	920 registros, 25 atributos (100 linhas)	CSV	CC BY 4.0
Textual	OPAS/OMS; SciELO / Arq. Bras. Cardiol.; Projeto Gutenberg (duas obras)	4 textos, cerca de 93 mil palavras (2 textos)	TXT (UTF-8)	Domínio público; CC BY-NC 3.0 (artigo)
Visual	PTB-XL / PhysioNet	120 ECG de 12 derivações, 5 classes (100 imagens)	PNG	CC BY 4.0

2. Dados numéricos (aprendizado de máquina e IoT clínico)

O conjunto numérico reúne 920 registros de pacientes avaliados para doença arterial coronariana, extraídos da base *Heart Disease* do repositório de aprendizado de máquina da Universidade da Califórnia em Irvine. A base resulta da união de quatro instituições — a Cleveland Clinic Foundation, o Hungarian Institute of Cardiology, hospitais universitários da Suíça e o centro médico da Administração de Veteranos em Long Beach — e é distribuída sob licença Creative Commons Attribution 4.0. Cada registro descreve um paciente por meio de vinte e cinco atributos, entre eles idade, sexo, pressão arterial em repouso, colesterol sérico, tipo de dor torácica, resultado do eletrocardiograma de repouso, frequência cardíaca máxima em teste de esforço e o desnível do segmento ST. A variável de desfecho indica a presença e a extensão de obstrução coronariana confirmada por angiografia, e foi mantida tanto na forma original, de zero a quatro vasos acometidos, quanto em uma versão binária. O mínimo exigido pela atividade eram cem linhas.

Do ponto de vista clínico, as variáveis mais relevantes para um modelo de risco são as que representam fatores modificáveis ou marcadores diretos de isquemia. A pressão arterial, o colesterol e a glicemia de jejum elevada são os principais alvos de prevenção; o tipo de dor torácica orienta a probabilidade de doença antes de qualquer exame; a frequência cardíaca máxima e a angina desencadeada por esforço traduzem a resposta do coração ao aumento de demanda; o desnível do segmento ST e o número de vasos corados à fluoroscopia informam a carga aterosclerótica já instalada. Idade e sexo, embora não modificáveis, condicionam a interpretação de todo o restante; no caso do sexo, merecem atenção porque a apresentação da doença coronariana na mulher é historicamente subvalorizada, o que se reflete nos próprios dados. No preparo do arquivo, os valores ausentes foram preservados de forma explícita, sem imputação, e os registros de colesterol ou pressão iguais a zero — fisiologicamente impossíveis e, na prática, indicativos de medida não realizada — foram convertidos em ausência.

3. Dados textuais (processamento de linguagem natural)

Foram reunidos quatro textos sobre doença cardiovascular, que somam aproximadamente noventa e três mil palavras, em português e em inglês; o mínimo exigido eram dois. Dois deles são contemporâneos: a folha informativa da Organização Pan-Americana da Saúde sobre doenças cardiovasculares e um artigo dos *Arquivos Brasileiros de Cardiologia*, obtido na biblioteca SciELO, que descreve a evolução da prevalência das cardiopatias no Brasil ao longo de seis décadas. Os outros dois são obras médicas do início do século XX, de domínio público, obtidas no Projeto Gutenberg: um tratado sobre doenças do coração e das artérias, de 1901, e outro sobre aterosclerose e hipertensão, de 1912. Cada arquivo foi normalizado para texto simples e recebeu um cabeçalho com título, fonte, idioma e licença.

O corpus foi montado tendo em vista as tarefas de linguagem previstas para as fases seguintes. Os materiais de divulgação e os tratados clínicos são densos em descrição de sintomas — dor torácica, dor irradiada para o braço ou a mandíbula, falta de ar, sudorese, palpitação, síncope —, o que permite construir e avaliar extratores de sinais e sintomas a partir de texto livre, ponto de partida para o módulo de triagem. O artigo científico apresenta uma organização explícita das cardiopatias em grupos, que serve de referência para a classificação de tópicos. O contraste entre o tom preventivo do material da OPAS e o tom prognóstico das obras históricas fornece um material inicial para calibrar a análise de sentimento em contexto clínico, e a distância entre a terminologia de 1901 e a atual é útil ao trabalho de normalização de vocabulário. O interesse prático é claro: grande parte da informação assistencial é registrada como texto livre e, sem processamento de linguagem, não alcança os modelos.

4. Dados visuais (visão computacional)

O conjunto visual é composto por 120 imagens de eletrocardiograma de doze derivações, geradas a partir de sinais reais da base PTB-XL, mantida pelo PhysioNet e licenciada sob Creative Commons Attribution 4.0; o mínimo exigido eram cem imagens de um mesmo tipo de exame. Cada imagem corresponde a um registro de dez segundos de um paciente real, com laudo elaborado por cardiologista, e foi traçada no formato convencional de leitura, a 25 mm/s e 10 mm/mV, sobre a grade milimetrada. As imagens estão rotuladas em cinco categorias diagnósticas — eletrocardiograma normal, infarto do miocárdio, alteração da repolarização (ST-T), distúrbio de condução e sobrecarga ventricular —, com vinte e quatro exames por categoria e igual número de exames de pacientes de cada sexo. Foram selecionados apenas registros com laudo validado por especialista e com um único achado dominante, para que o rótulo de cada imagem seja inequívoco.

O eletrocardiograma foi escolhido por ser o exame cardiológico de maior disponibilidade e menor custo, além de altamente padronizado — características que favorecem a análise automática. Sobre essas imagens é possível exercitar segmentação e detecção de bordas, para separar o traçado da grade e isolar cada derivação; detecção de picos, para localizar os complexos QRS e estimar a frequência e o ritmo; classificação supervisionada, para associar a imagem a um achado; e detecção de anomalias, para sinalizar padrões como o supradesnível do segmento ST, sugestivo de infarto agudo. A existência do rótulo por categoria desde esta fase permite tratar a sensibilidade do classificador como prioridade, uma vez que deixar de identificar um infarto tem consequência mais grave do que um alarme falso.

5. Governança de dados e viés

A opção por fontes públicas e anonimizadas atende aos princípios de minimização e de finalidade e dispensa, nesta fase, base legal específica para o tratamento de dados pessoais sensíveis. Cada fonte foi registrada com endereço, identificador, ano e licença, e as três bases podem ser reconstruídas a partir dos dados brutos por meio dos roteiros incluídos no repositório, o que torna as transformações verificáveis.

Os principais vieses foram medidos e documentados. Na base numérica, 78,9% dos pacientes são homens, e a instituição suíça, por ser um centro de referência, contribui quase apenas com casos de doença; isso exige validação separada por origem e por sexo e recomenda que a instituição não seja usada como variável preditora. As variáveis obtidas por cateterismo e por cintilografia têm mais da metade dos valores ausentes, de forma associada à instituição de coleta. As imagens refletem uma população europeia examinada entre 1989 e 1996, e os textos concentram-se em dois idiomas e em dois períodos históricos distantes entre si. Nenhuma dessas bases representa a população brasileira ou a prática atual do Sistema Único de Saúde; são adequadas para prototipagem, e a coleta de dados locais ficou registrada como tarefa das fases seguintes.

6. Organização do repositório e reprodutibilidade

O repositório parte do modelo oficial da FIAP. Os textos estão em `assets/textos`; os dados numéricos e as imagens, com os respectivos roteiros de preparação, em `dados/numericos` e `dados/visuais`; os documentos do projeto, incluindo este resumo e a análise de governança e viés, em `document`. A pasta `notebooks` traz um caderno inicial que carrega os três conjuntos e confirma a sua integridade. O

conjunto completo também está disponível, em pacote único, como versão publicada no GitHub e em pasta pública no Google Drive, ambas acessíveis sem autenticação.

7. Considerações finais

Ao término desta fase, os três tipos de dado estão reunidos, todos a partir de fontes reais e em quantidade superior ao mínimo solicitado, com rótulos já definidos para os conjuntos numérico e visual. Mais do que a coleta, o trabalho procurou tornar explícitos a procedência, o tratamento aplicado e as limitações de cada base, de forma que as decisões das próximas fases — sobretudo as relativas a viés e representatividade — sejam tomadas com conhecimento de causa.

Referências

1. JANOSI, A.; STEINBRUNN, W.; PFISTERER, M.; DETRANO, R. *Heart Disease*. UCI Machine Learning Repository, 1989. DOI: 10.24432/C52P4X.
2. WAGNER, P. *et al.* PTB-XL, a large publicly available electrocardiography dataset. *Scientific Data*, v. 7, art. 154, 2020.
3. EVORA, P. R. B.; NATHER, J. C.; RODRIGUES, A. J. Prevalência das doenças cardíacas ilustrada em 60 anos dos Arquivos Brasileiros de Cardiologia. *Arquivos Brasileiros de Cardiologia*, v. 102, n. 1, p. 9-16, 2014.
4. ORGANIZAÇÃO PAN-AMERICANA DA SAÚDE. *Doenças cardiovasculares*. Folha informativa. Disponível em: paho.org. Acesso em: set. 2026.
5. BRUCE, J. M. *The Lettsomian Lectures on Diseases and Disorders of the Heart and Arteries in Middle and Advanced Life*. Londres, 1901. (Project Gutenberg, 43780).
6. WARFIELD, L. M. *Arteriosclerosis and Hypertension, with Chapters on Blood Pressure*. 1912. (Project Gutenberg, 37675).